

2026 RAPPORT

Prédiction d'une
variable quantitative

Par
Nolan FONTAINE
Noa DOUIT



Ce qu'on a retenu du Machine Learning

1. Les trois piliers de la démarche

Pour qu'un algorithme puisse apprendre et s'auto-améliorer, trois ingrédients sont indispensables :

- Les données : Elles constituent la base d'apprentissage.
- Le modèle : C'est la structure mathématique choisie pour construire la fonction de décision.
- L'algorithme : De nature adaptative, il ajuste les paramètres du modèle jusqu'à atteindre une décision optimale.

2. Apprendre et Généraliser

L'objectif central du ML :

- Apprendre : Ajuster le modèle pour reproduire au mieux le comportement des données connues (entraînement).
- Généraliser : Être capable de fournir des prédictions robustes sur des données nouvelles, que la machine n'a jamais rencontrées.

3. Les types d'apprentissage

On distingue principalement trois modes selon la nature des objectifs:

- Supervisé : L'algorithme s'entraîne sur des couples "entrée/sortie" étiquetés (ex: prédire un diamètre de tumeur selon des tests médicaux).
- Non supervisé : La machine explore des données non étiquetées pour y déceler des structures ou des regroupements.
- Par renforcement : Un agent apprend la meilleure stratégie en recevant des récompenses ou des sanctions selon ses actions dans un environnement.

4. La gestion du risque

L'évaluation de la performance est l'étape la plus critique. Deux pièges doivent être évités :

- Le surapprentissage : Le modèle est trop complexe et "apprend par cœur" les données d'entraînement, perdant ainsi sa capacité à généraliser sur de nouvelles données.
- Le sous-apprentissage : Le modèle est trop simple et ne parvient même pas à capturer la structure des données de base.

Notre démarche de résolution

1. Préparation, Audit et Nettoyage des Données

La première étape de notre démarche a consisté à importer et préparer le jeu de données `cancer_sae2026.csv`. L'objectif ici est de s'assurer que les données transmises à l'algorithme sont propres, fiables et dans un format mathématique correct, afin de ne pas fausser les résultats dès le départ.

1.1. Importation sécurisée et typage des données

Lors du chargement du fichier avec la bibliothèque Pandas, nous avons été très précis sur les paramètres d'importation, notamment avec `sep=';`' et `na_values="."`. Ce dernier paramètre est crucial : dans le domaine médical ou selon les logiciels utilisés, un point "." est souvent saisi pour indiquer qu'une donnée est absente. Si nous n'avions pas précisé cela à Python, il aurait considéré ces points comme du texte, transformant des colonnes entières de nombres en format texte (**object**).

Grâce à cette précaution, l'instruction `info()` confirme que nos données sont saines : nous avons bien 20 000 patients (lignes) et 12 colonnes. Toutes les variables médicales (X1 à X10) ainsi que la taille de la tumeur (Y) sont correctement reconnues comme des nombres décimaux (**float64**). L'algorithme pourra donc faire ses calculs sans erreur de format.

```
--- Informations sur le jeu de données ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype  
---  -
0   identifiant 20000 non-null  int64  
1   X1          19997 non-null  float64
2   X2          20000 non-null  float64
3   X3          19996 non-null  float64
4   X4          20000 non-null  int64  
5   X5          20000 non-null  float64
6   X6          20000 non-null  float64
7   X7          19996 non-null  float64
8   X8          20000 non-null  float64
9   X9          20000 non-null  float64
10  X10         20000 non-null  float64
11  y           20000 non-null  float64
dtypes: float64(10), int64(2)
memory usage: 1.8 MB
```

1.2. Suppression de la variable "identifiant" (Prévention du bruit)

Le jeu de données contient une colonne **identifiant**. Il s'agit simplement du numéro de dossier du patient.

D'un point de vue médical et statistique, ce numéro n'a absolument aucune influence sur la taille de la tumeur (la variable cible Y). Si nous laissons cette colonne, l'algorithme de Machine Learning essaierait quand même d'y trouver une logique mathématique. Il risquerait de créer des règles absurdes (par exemple : "les patients dont l'identifiant est supérieur à 10 000 ont de plus grosses tumeurs"). Pour éviter que le modèle n'apprenne des relations fausses (surapprentissage), nous avons pris la décision de supprimer définitivement cette colonne avant d'aller plus loin.

1.3. Traitement des valeurs manquantes : un choix justifié

En vérifiant si notre tableau était complet (via `isnull().sum()`), nous avons repéré quelques cases vides sur trois tests médicaux :

- X1 : 3 valeurs manquantes
- X3 : 4 valeurs manquantes
- X7 : 4 valeurs manquantes

Cela représente seulement 11 valeurs manquantes sur un total de 20 000 patients. Face à ce constat, nous devons justifier notre stratégie d'intervention :

```
--- Valeurs manquantes par variable ---
identifiant    0
X1             3
X2             0
X3             4
X4             0
X5             0
X6             0
X7             4
X8             0
X9             0
X10            0
y              0
dtype: int64
```

A. Pourquoi ne pas supprimer les lignes ?

La solution de facilité aurait été de supprimer les 11 patients concernés. Cependant, c'est une mauvaise pratique. Un patient à qui il manque le test X1 possède tout de même des résultats parfaitement valides pour les 9 autres tests. Supprimer la ligne entière reviendrait à détruire de l'information médicale utile. Nous avons donc choisi de remplacer (imputer) ces valeurs vides.

B. Pourquoi choisir le SimpleImputer plutôt que l'IterativeImputer ?

Scikit-Learn propose des outils très complexes, comme l'**IterativeImputer**, qui utilise l'Intelligence Artificielle pour deviner les valeurs manquantes en s'aidant de toutes les autres colonnes. Cependant, utiliser un algorithme aussi lourd et gourmand en temps de calcul pour deviner seulement 11 cases vides dans un tableau qui en contient 200 000 n'a pas de sens technique. Le gain de précision serait invisible. Par souci d'efficacité, nous avons choisi l'outil le plus direct : le **SimpleImputer**.

C. Pourquoi remplacer par la médiane et non par la moyenne ?

```
--- Statistiques des variables avec valeurs manquantes ---
```

	X1	X3	X7
count	19997.0000	19996.0000	19996.0000
mean	0.2707	0.3104	8.6052
std	1.5364	0.1441	1.4472
min	0.0000	0.0427	6.1000
25%	0.1250	0.1871	7.3500
50%	0.2500	0.3098	8.6000
75%	0.3750	0.4346	9.8500
max	150.0000	0.5774	11.1000

Le **SimpleImputer** nous oblige à choisir une valeur de remplacement : la moyenne ou la médiane. Pour prendre la bonne décision, nous avons observé les statistiques des colonnes concernées.

Nous avons remarqué que la variable X1 possède des valeurs extrêmes très fortes : la plupart des patients ont un score autour de 0.25 (la médiane), mais au moins un patient atteint un score de 150.

La moyenne est très sensible : ce score de 150 suffit à tirer artificiellement la moyenne vers le haut. Si nous avons utilisé la moyenne pour remplir les cases vides, nous aurions faussé les données avec une valeur trop haute. À l'inverse, la médiane est robuste : elle ignore complètement les valeurs extrêmes. C'est pourquoi nous avons paramétré notre imputer strictement sur la médiane (**strategy='median'**), garantissant un remplacement fiable et représentatif de la majorité des patients.

2. Exploration analytique et diagnostic des données

Une fois la matrice de données assainie et imputée, l'étape suivante consiste à réaliser une analyse exploratoire des distributions. L'objectif est d'évaluer les ordres de grandeur, la dispersion temporelle ou spatiale, et l'homogénéité des variables explicatives avant de les soumettre à notre algorithme d'apprentissage.

--- Statistiques descriptives de toutes les variables explicatives ---										
	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
count	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000	20000.0000
mean	0.2707	383.5876	0.3104	250.5858	5.5431	579.9678	8.6052	214.7804	1052.7238	0.8732
std	1.5363	1.4380	0.1441	147.2838	2.4294	26.1374	1.4471	89.2014	84.0059	0.7146
min	0.0000	381.1000	0.0427	0.0000	0.0000	11.0000	6.1000	9.0000	1032.2000	0.0000
25%	0.1250	382.3500	0.1872	125.0000	3.6750	576.0500	7.3500	144.5000	1045.2500	0.7350
50%	0.2500	383.6000	0.3098	250.0000	5.5250	579.8500	8.6000	215.0000	1051.9500	0.8600
75%	0.3750	384.8500	0.4346	375.0000	7.4250	583.6000	9.8500	284.5000	1058.4500	0.9862
max	150.0000	386.1000	0.5774	3000.0000	25.0000	3500.0000	11.1000	420.0000	9800.1200	75.0000

2.1. Audit des distributions et disparité dimensionnelle

L'analyse du tableau des statistiques descriptives (généré via la méthode `describe()`) appliqué à nos dix variables explicatives (X1 à X10) met en exergue deux problématiques statistiques majeures qui conditionneront toute notre stratégie de modélisation :

A. Une forte hétérogénéité des échelles (Disparité dimensionnelle) :

Nous constatons une très grande disparité dans la dispersion des variables. Par exemple, la variable X3 présente un écart-type extrêmement faible de 0.1441, tandis que la variable X4 affiche un écart-type de 147.2838. Les ordres de grandeur diffèrent drastiquement : la moyenne de X1 est d'environ 0.27, alors que celle de X9 dépasse 1052.

Cette non-homogénéité flagrante indique qu'il sera impératif de procéder à une mise à l'échelle (via un `StandardScaler` ou `RobustScaler`). Sans cette étape de centrage et de réduction, les variables aux valeurs absolues élevées dicteraient artificiellement la fonction de coût du modèle, masquant l'influence prédictive des variables aux échelles plus petites.

B. Une forte asymétrie et la présence de valeurs atypiques (Outliers) :

L'analyse des étendues met en lumière des distributions fortement asymétriques (asymétrie positive étalée vers la droite). Pour plusieurs variables, la valeur maximale (max) est mathématiquement disproportionnée par rapport au 3ème quartile (Q3), suggérant la présence de valeurs extrêmes :

- Pour X1, 75 % des observations sont inférieures à 0.375, mais le maximum culmine à 150.
- Pour X4, le 3ème quartile est à 375, mais le maximum s'envole à 3000.
- Pour X6, 75 % des valeurs sont sous 583.6, avec un maximum à 3500.
- Les variables X9 (maximum à 9800.12) et X10 (maximum à 75 face à un Q3 de 0.9862) présentent le même comportement erratique.

Face à ces constats chiffrés, l'utilisation d'un outil de diagnostic visuel devient indispensable pour confirmer ces anomalies de distribution.

2.2. Diagnostic visuel par boîtes à moustaches et impact sur le modèle


La génération du graphique des boîtes à moustaches confirme visuellement et de manière frappante les deux hypothèses soulevées par les statistiques descriptives :

A. L'écrasement visuel lié aux échelles :

La variable X9, avec ses valeurs s'approchant de 10 000, "écrase" l'axe des ordonnées du graphique. Les boîtes des autres variables deviennent minuscules et illisibles en comparaison. Cela valide définitivement la nécessité absolue d'appliquer une standardisation préalable des données pour que l'algorithme évalue chaque test médical sur un pied d'égalité.

B. La menace des valeurs extrêmes sur la Régression Linéaire :

Le graphique révèle une multitude de points situés au-delà des moustaches supérieures (et parfois inférieures) pour la quasi-totalité des tests médicaux. Statistiquement, ces points se situent au-delà de la limite théorique de $Q3 + (1.5 \times IQR)$ (l'Écart Interquartile).





Dans le cadre de la prédiction du diamètre tumoral (Y) via une Régression Linéaire Multiple (RLM), ces valeurs atypiques représentent un danger majeur. L'algorithme de RLM repose sur l'estimateur des Moindres Carrés Ordinaires (MCO), qui cherche à minimiser la somme des carrés des erreurs. Par nature mathématique, élever une erreur au carré donne un "poids" ou une "attraction" démesurée aux points éloignés. Ces outliers agissent comme des points leviers qui risquent de tordre et de biaiser l'hyperplan de régression, dégradant ainsi la capacité de généralisation du modèle sur des patients standards.

Il est donc impératif de traiter cette problématique avec la plus grande rigueur scientifique. Conformément aux exigences d'une étude de Data Science exhaustive, nous allons modéliser, évaluer et comparer trois scénarios distincts :

1. Un modèle ignorant ces valeurs (Sans les valeurs extrêmes).
2. Un modèle les atténuant via un plafonnement mathématique (Après écrêtement).
3. Un modèle les conservant, en utilisant des outils de mise à l'échelle robustes.


3. Traitement des valeurs extrêmes : Choix du critère de détection

Avant d'entraîner nos différents modèles (notamment celui impliquant la suppression des valeurs atypiques), il est indispensable de définir un critère mathématique rigoureux pour les détecter. Deux approches statistiques s'affrontent ici : la méthode interquartile (IQR) basée sur les statistiques d'ordre, et la méthode du Z-score basée sur la standardisation.

3.1. Analyse visuelle des distributions (Histogrammes et densités KDE)

La théorie statistique stipule que la méthode du Z-score n'est valide que si la distribution sous-jacente s'approche d'une loi normale. Dans ce cadre strict, la règle empirique des "3 sigmas" (68-95-99.7) s'applique parfaitement.

Pour vérifier la validité de cette hypothèse de normalité, nous avons généré la matrice des histogrammes couplés à l'estimation par noyau de la densité de probabilité (KDE - Kernel Density Estimation) pour nos dix variables explicatives.



Interprétation : L'examen visuel dissipe immédiatement l'hypothèse de normalité globale. Si quelques rares tests présentent une distribution approximativement symétrique (Gaussienne), la vaste majorité du jeu de données (notamment X1, X4, X6 et X9) souffre d'une asymétrie positive sévère. On observe une très forte concentration des observations dans des intervalles étroits à gauche (le mode de la distribution), couplée à des "queues de distribution" extrêmement épaisses qui s'étalent très loin vers la droite.

Ce constat visuel flagrant d'asymétrie contredit fondamentalement les prérequis de la méthode du Z-score, nous laissant présager son inefficacité sur notre jeu de données.

3.2. Comparaison empirique et confirmation mathématique du choix (IQR vs Z-score)

Afin d'écarter toute supposition et de baser notre choix sur une preuve tangible, nous avons codé et comparé empiriquement les capacités de détection des deux méthodes (IQR et Z-score) sur l'ensemble de nos variables.

L'analyse révèle globalement un pourcentage d'anomalies très faible (inférieur à 0.15 % par variable). Cependant, la confrontation des deux méthodes sur la variable X1 est révélatrice du danger des estimateurs non robustes :

- La méthode IQR y détecte 0.1250 % de valeurs atypiques.
- La méthode du Z-score n'en détecte que 0.0150 %.

--- DÉTECTION DES VALEURS EXTRÊMES : MÉTHODE IQR (BOÎTES À MOUSTACHES) ---

Pourcentage de valeurs extrêmes	X1	: 0.1250%
Pourcentage de valeurs extrêmes	X2	: 0.0000%
Pourcentage de valeurs extrêmes	X3	: 0.0000%
Pourcentage de valeurs extrêmes	X4	: 0.0250%
Pourcentage de valeurs extrêmes	X5	: 0.0250%
Pourcentage de valeurs extrêmes	X6	: 0.0400%
Pourcentage de valeurs extrêmes	X7	: 0.0000%
Pourcentage de valeurs extrêmes	X8	: 0.0000%
Pourcentage de valeurs extrêmes	X9	: 0.0100%
Pourcentage de valeurs extrêmes	X10	: 0.0550%

--- DÉTECTION DES VALEURS EXTRÊMES : MÉTHODE DU Z-SCORE ---

Pourcentage de valeurs extrêmes	X1	: 0.0150%
Pourcentage de valeurs extrêmes	X2	: 0.0000%
Pourcentage de valeurs extrêmes	X3	: 0.0000%
Pourcentage de valeurs extrêmes	X4	: 0.0250%
Pourcentage de valeurs extrêmes	X5	: 0.0250%
Pourcentage de valeurs extrêmes	X6	: 0.0400%
Pourcentage de valeurs extrêmes	X7	: 0.0000%
Pourcentage de valeurs extrêmes	X8	: 0.0000%
Pourcentage de valeurs extrêmes	X9	: 0.0100%
Pourcentage de valeurs extrêmes	X10	: 0.0400%



Cette sous-détection flagrante de la part du Z-score s'explique par un phénomène statistique bien connu : l'effet de masquage. Mathématiquement, le Z-score se calcule en utilisant la moyenne arithmétique et l'écart-type. Or, comme nous l'avons vu précédemment, la variable X_1 possède une valeur maximale aberrante de 150. Cette seule valeur extrême suffit à "tirer" la moyenne vers le haut et, surtout, à gonfler artificiellement la variance et l'écart-type de toute la variable. Par conséquent, la frontière de détection des 3 écarts-types devient beaucoup trop large et permissive, rendant le Z-score totalement aveugle aux réelles anomalies qu'il est censé détecter.

À l'inverse, la méthode IQR (Écart Interquartile) repose exclusivement sur les quartiles (Q_1 , Q_2 , Q_3) qui sont des statistiques de position (comme la médiane). Leur point de rupture étant élevé, ils sont strictement insensibles aux valeurs extrêmes.

Conclusion de l'étape : Le Z-score exigeant une normalité absente ici et souffrant de l'effet de masquage, il est techniquement disqualifié. Nous validons donc officiellement la méthode IQR (associée conceptuellement aux boîtes à moustaches) comme critère de détection pour la suite de nos modélisations, garantissant ainsi une robustesse mathématique à toute épreuve face aux asymétries de nos données.

4. Ingénierie des données, Modélisation et Évaluation des stratégies

Avant de confronter nos données à l'algorithme des Moindres Carrés Ordinaires (Régression Linéaire Multiple), une ultime phase de préparation mathématique a été nécessaire pour configurer notre environnement d'apprentissage.

4.1. Séparation des données et prévention des fuites

Conformément aux bonnes pratiques du Machine Learning, nous avons scindé notre jeu de données en deux sous-ensembles via la fonction `train_test_split` :

- Un ensemble d'apprentissage (Train - 80 %) : dédié exclusivement à l'entraînement de l'algorithme.
- Un ensemble de test (Test - 20 %) : conservé de côté, invisible pour le modèle, afin d'évaluer sa capacité réelle de généralisation sur des patients inconnus.

Ensuite, pour pallier la forte hétérogénéité des échelles identifiée lors de l'exploration initiale, nous avons appliqué un centrage et une réduction (**StandardScaler**). Choix méthodologique crucial : L'ajustement de ce scaler (**fit**) a été calculé uniquement sur l'ensemble d'apprentissage. L'ensemble de test n'a subi qu'une transformation (**transform**) basée sur les paramètres du Train. Cette précaution est indispensable : si nous avons standardisé l'ensemble des données avant la séparation, des informations statistiques de l'ensemble de test auraient "fuité" vers l'ensemble d'apprentissage (Data Leakage), biaisant ainsi l'évaluation finale.


4.2. Stratégie d'évaluation : R^2 et Validation Croisée (K-Fold)

Pour évaluer nos modèles de manière implacable, nous avons croisé deux métriques :

- Le coefficient de détermination (R^2) : Il mesure la proportion de la variance de la taille de la tumeur expliquée par nos tests médicaux (pouvoir explicatif).
- La Validation Croisée (K-Fold avec $k=5$) : Évaluer un modèle sur une seule séparation 80/20 peut masquer un "coup de chance" au tirage. La validation croisée découpe l'ensemble d'apprentissage en 5 blocs. L'algorithme s'entraîne sur 4 blocs et se teste sur le 5ème, et ce, 5 fois de suite. Nous obtenons ainsi un Score moyen et un Écart-type, garantissant la stabilité de notre modèle face aux variations de l'échantillon.

4.3. Modèle 1 : Suppression des valeurs extrêmes (Méthode IQR)

Dans cette première démarche, nous avons fait le choix de purifier la matrice de données en excluant toutes les observations identifiées comme atypiques par la méthode interquartile ($Q1 - 1.5 * IQR$ et $Q3 + 1.5 * IQR$). Sur notre cohorte initiale de 20 000 patients, notre script a supprimé 56 dossiers médicaux. Cela représente une perte d'information extrêmement marginale (0.28 %), nous autorisant à procéder à la modélisation sans crainte de sous-représentativité.



Résultats de l'algorithme :

- Score R^2 (sur Apprentissage) : 0.9058 (Soit 90.58 % de variance expliquée)
- Score moyen en Validation Croisée (CV) : 0.9056
- Écart-type de la CV : 0.0045



Interprétation : Le pouvoir prédictif de ce modèle est excellent. Mieux encore, la proximité quasi parfaite entre le R^2 d'entraînement (0.9058) et la moyenne de la validation croisée (0.9056) prouve l'absence totale de surapprentissage. L'écart-type très faible (0.0045) confirme que le modèle est stable et hautement reproductible.

4.4. Modèle 2 : Atténuation par Écrêtement (Winsorisation à 5 %)

Bien que le Modèle 1 soit performant, la suppression pure et simple de patients (même en faible quantité) reste une décision lourde en Data Science médicale, car elle engendre une perte sèche d'informations potentiellement précieuses. Pour notre deuxième étude, nous avons opté pour une technique plus conservative : l'écrêtement.


Justification des choix paramétriques et algorithmiques

Pourquoi avoir choisi 5 % (0.05) et non 1 % ou 10 % ? Notre analyse exploratoire initiale (via les boîtes à moustaches et les histogrammes) a révélé que les valeurs atypiques présentaient de très longues queues de distribution, particulièrement étirées vers la droite (asymétrie positive forte). Un seuil trop faible (comme 1 %, soit 0.01) aurait été largement insuffisant pour neutraliser l'intégralité des valeurs aberrantes qui s'épalaient parfois jusqu'à des extrêmes de 150 ou 3000. À l'inverse, un seuil trop agressif (comme 10 %, soit 0.10) aurait dénaturé la distribution en écrasant des valeurs biologiques parfaitement légitimes, détruisant ainsi la variance naturelle dont l'algorithme a besoin pour apprendre. Le seuil de 5 % représente donc le point d'équilibre optimal entre l'assainissement statistique et la préservation de l'intégrité des données d'origine.

Explication de l'écèlement

Via la fonction **winsorize** de Scipy, nous avons "écèlement" les données : les valeurs situées au-delà du 95ème centile (et en deçà du 5ème centile) ont été rabattues (plafonnées) sur ces mêmes seuils. Ainsi, aucun patient n'est supprimé, mais l'impact mathématique démesuré de leurs tests extrêmes est neutralisé.

Boxplot de la variable X4 AVANT écèlement VS APRÈS écèlement



Résultats de l'algorithme

- Score R^2 (sur Apprentissage) : 0.9038
- Score moyen en Validation Croisée (CV) : 0.9037
- Écart-type de la CV : 0.0018

Interprétation : Le pouvoir explicatif global (R^2) baisse d'une infime fraction par rapport au Modèle 1 (0.9038 contre 0.9058). Cependant, ce modèle révèle une supériorité structurelle frappante : sa variance prédictive est divisée par plus de deux ! L'écart-type de sa validation croisée chute à 0.0018. En conservant tous les patients tout en lissant les aberrations, le modèle atteint une stabilité statistique exceptionnelle.

4.5. Modèle 3 : Conservation des données brutes

Pour cette ultime modélisation, nous avons délibérément conservé l'intégralité des valeurs atypiques brutes. Notre seule ligne de défense a été d'appliquer un **RobustScaler** (mise à l'échelle basée sur la médiane et les quartiles, peu sensible aux extrêmes) en amont du **StandardScaler**.

Résultats de l'algorithme :

- Score R^2 (sur Apprentissage) : 0.9051
- Score moyen en Validation Croisée (CV) : 0.8978
- Écart-type de la CV : 0.0139

Interprétation : Contrairement à ce que l'on pourrait redouter, la présence des valeurs extrêmes n'a pas provoqué un effondrement total du modèle. L'algorithme parvient tout de même à expliquer près de 90.5 % de la variance sur l'ensemble d'entraînement, et conserve un score moyen très honorable d'environ 89.8 % en validation croisée.

Cependant, le diable se cache dans les détails statistiques : la variance de ce modèle a explosé. L'écart-type de la validation croisée (0.0139) est près de 3 fois supérieur à celui du Modèle 1 (0.0045) et près de 8 fois supérieur à celui du Modèle 2 (0.0018).

Explication : Les valeurs extrêmes ont agi comme des points leviers. Selon le découpage aléatoire des blocs lors du K-Fold, ces patients atypiques se retrouvent soit dans l'ensemble d'entraînement (où ils tirent fortement l'hyperplan de régression vers eux), soit dans l'ensemble de test (où ils génèrent d'énormes résidus au carré). Cela crée une forte instabilité mathématique. Le modèle est donc très sensible aux fluctuations de l'échantillon, ce qui le rend risqué pour un déploiement clinique à grande échelle.

5. Conclusion et Sélection Définitive du Modèle

L'analyse comparative de nos trois scénarios permet de tirer des conclusions claires sur la gestion de la donnée médicale face à un algorithme de Régression Linéaire Multiple :

1. Le Modèle 3 (Données brutes) démontre qu'ignorer les valeurs extrêmes rend le modèle trop instable (écart-type CV élevé), car l'algorithme des Moindres Carrés Ordinaires pénalise excessivement les points éloignés.
2. Le Modèle 1 (Suppression via IQR) offre d'excellentes performances globales, mais impose le sacrifice éthique et statistique de supprimer des patients de la cohorte.

Le choix final se porte donc sans équivoque sur le Modèle 2 (Atténuation par Winsorisation).

Justification finale de notre choix :

- 1. L'Exhaustivité : Dans le cadre de la prédiction du diamètre tumoral, chaque observation clinique est précieuse. La méthode de l'écrêtement nous permet de n'exclure aucun dossier médical, maximisant ainsi l'information disponible pour l'apprentissage.
- 2. L'Hyper-Stabilité (Robustesse) : En plafonnant les 5 % d'excès bilatéraux, nous avons supprimé la menace des points leviers. Bien que ce modèle concède une infime fraction de R^2 en apprentissage, il offre une variance prédictive exceptionnellement basse (écart-type en validation croisée de 0.0018). Il s'agit de loin du modèle le plus constant, le plus équilibré et le moins sujet aux "caprices" de l'échantillonnage. Il garantit ainsi des prédictions fiables, sereines et généralisables lors de sa future mise en production.



SAE Prediction

FIN

Prédiction d'une
variable quantitative

Premiers pas dans le
Machine Learning

Par
Nolan FONTAINE
Noa DOUIT



Abdellah Qannari 